

Unidad III - SOLUCIÓN DE SISTEMAS DE ECUACIONES LINEALES

- Métodos directos. Métodos para matrices triangulares. Método de Eliminación de Gauss. Descomposición LU. Estrategia de pivoteo y escalamiento. Cálculo de la inversa. Métodos para matrices especiales: Cholesky, Thomas.
- Análisis del error: concepto de norma, número de condición, cotas de error. Método de los residuos.
- Métodos iterativos: Gauss Jacobi, Gauss Seidel. Método SOR. Análisis del error y la convergencia.

Análisis del Error en Sistemas de Ecuaciones Lineales

Dado el sistema de ecuaciones lineales de la forma

$$Ax = b, \text{ donde } A \in \mathbb{R}^{n \times n}; \quad b \in \mathbb{R}^n$$

En realidad tenemos:

$$(A + \delta A)(x + \delta x) = (b + \delta b)$$

$$Ax + A\delta x + \delta Ax + \delta A\delta x = Ax + \delta b$$

Si despreciamos $\delta A\delta x$:

$$\delta x = A^{-1}(\delta b - \delta Ax)$$

Análisis del Error Sistemas de Ecuaciones Lineales

Dado el sistema de ecuaciones lineales de la forma

$$Ax = b, \text{ donde } A \in \mathbb{R}^{n \times n}; \quad b \in \mathbb{R}^n$$

$$\delta x = A^{-1}(\delta b - \delta Ax)$$

Si se quiere tener una estimación numérica de la magnitud del error es necesario considerar la norma de estos vectores y matrices

$$\|\delta x\| \leq \|A^{-1}\| \|\delta b - \delta Ax\|$$

Norma

Medida escalar de la magnitud de un vector o una matriz.

Norma Vectorial: Dado un vector $X \in \mathbb{R}^n$, definimos **norma p**

$$\|X\|_p = \left(\sum_{i=1}^n |x_i|^p \right)^{1/p}$$

$$p=1: \|X\|_1 = \sum_{i=1}^n |x_i|$$

$$p=2: \|X\|_2 = \|X\|_e = \sqrt{\sum_{i=1}^n x_i^2} \quad \text{Norma euclidiana}$$

$$p=\infty: \|X\|_\infty = \max_{1 \leq i \leq n} |x_i|$$

Norma

Ejemplos:

$$x^T = (4, -3, 1)$$

$$\|X\|_1 = \sum_{i=1}^n |x_i| = (4 + 3 + 1) = 8$$

$$\|X\|_2 = \sqrt{\sum_{i=1}^n x_i^2} = \sqrt{16 + 9 + 1} = 5.1$$

$$\|X\|_\infty = \max_{1 \leq i \leq n} |x_i| = \max(4, 3, 1) = 4$$

$$x^T = (-12, -1, 0, 4)$$

$$\|X\|_1 = \sum_{i=1}^n |x_i| = (12 + 1 + 0 + 4) = ?$$

$$\|X\|_2 = \sqrt{\sum_{i=1}^n x_i^2} = \sqrt{144 + 1 + 16} = ?$$

$$\|X\|_\infty = \max_{1 \leq i \leq n} |x_i| = \max(12, 1, 4) = ?$$

Norma Matricial


Dada una matriz $A \in \mathbb{R}^{n \times m}$, y si $\|\cdot\|$ es una norma vectorial definimos las normas matriciales, en función de las normas vectoriales definidas antes, con la siguiente expresión:


$$\|A\| = \max_{x \neq 0} \frac{\|Ax\|}{\|x\|} = \max_{\|x\|=1} \|Ax\|$$

Se llama **Norma Inducida**

Norma Matricial (Inducida)

$$\|A\| = \max_{x \neq 0} \frac{\|Ax\|}{\|x\|} = \max_{\|x\|=1} \|Ax\|$$

Norma Columna $\|A\|_1 = \max_j \sum_{i=1}^n |a_{ij}|$ 

Norma Fila $\|A\|_\infty = \max_i \sum_{j=1}^n |a_{ij}|$ 

Norma Raíz $\|A\|_2 = (\lambda_{\max})^{1/2}$,
 λ_{\max} : radio espectral de $[A]^T[A]$

Definición: Dada una matriz A cuadrada, se define el *radio espectral* de A y se denota por $\rho(A)$ como $\rho(A) = \max |\lambda|$ siendo λ valor propio de A.
 si λ es complejo, $\lambda = \alpha + \beta i$ se tiene $|\lambda| = \sqrt{\alpha^2 + \beta^2}$

Métodos Numéricos I 2024

7

Ejemplo:

$$A = \begin{bmatrix} -4 & 1 \\ 2 & -3 \end{bmatrix}$$

$$\|A\|_1 = \max_j \sum_{i=1}^n |a_{ij}| = \max((4+2); (1+3)) = \max(6, 4) = 6$$

$$\|A\|_\infty = \max_i \sum_{j=1}^n |a_{ij}| = \max((4+1); (2+3)) = \max(5, 5) = 5$$

$$\|A\|_2 = (\lambda_{\max})^{1/2} = (26.18)^{1/2} \approx 5.117$$

λ_{\max} : radio espectral de $A^T A$

$$A^T A = \begin{bmatrix} -4 & 1 \\ 2 & -3 \end{bmatrix} \begin{bmatrix} -4 & 2 \\ 1 & -3 \end{bmatrix} = \begin{bmatrix} 20 & -10 \\ -10 & 10 \end{bmatrix}$$

$$P(\lambda) = \det(A - \lambda I) = \lambda^2 - 30\lambda + 100 \rightarrow \sigma(A) = (3.82, 26.18) \rightarrow \lambda_{\max} = 26.18$$

Métodos Numéricos I 2024

8

Número de Condición

$$\text{Cond}(A) = \kappa(A) = \|A\| \|A^{-1}\|$$

- El producto de normas es una medida cuantitativa del grado de mal condicionamiento de la matriz de coeficientes. Mide cuán cerca está una matriz de ser singular
- Se usa para calcular cómo afectan los errores relativos en A y/o b el cálculo de x.
- Se puede demostrar que

$$\frac{\|\delta x\|}{\|x\|} \leq \kappa(A) \frac{\|\delta b\|}{\|b\|} \quad \text{y} \quad \frac{\|\delta x\|}{\|x + \delta x\|} \leq \kappa(A) \frac{\|\delta x\|}{\|A\|}$$

- Si A y b tienen t cifras significativas y $\kappa(A)$ es de un orden 10^s entonces la precisión del resultado será 10^{s-t}

Métodos Numéricos I 2024

9

Error en Sistemas Lineales

Teorema: Supongamos tener el sistema $Ax=b$, A no singular y sean δA y δb perturbaciones de A y de b, respectivamente, si se cumple que $\|A\| < 1/\|A^{-1}\|$ entonces:

$$\frac{\|\delta x\|}{\|x\|} \leq \frac{\kappa(A)}{1 - \kappa(A)} \frac{\|\delta A\|}{\|A\|} \left(\frac{\|\delta A\|}{\|A\|} + \frac{\|\delta b\|}{\|b\|} \right)$$

Vemos que un $\kappa(A)$ grande amplifica los errores en los datos

Métodos Numéricos I 2024

10

Sistema de ecuaciones mal condicionadas

- Una pequeño error en las entradas de la matriz A, causa una gran error en la solución

$$\begin{bmatrix} 1 & 1 \\ 1 & 1.01 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 2 \\ 2.01 \end{bmatrix} \Rightarrow \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

$$\begin{bmatrix} 1 & 2 \\ 1 & 1.01 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 2 \\ 2 \end{bmatrix} \Rightarrow \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 2 \\ 0 \end{bmatrix}$$

$$A^{-1} = \begin{bmatrix} 101 & -100 \\ -100 & 100 \end{bmatrix}$$

$$\Delta b = -0.01$$

$$\Delta x = ?$$

$$\kappa(A) = \|A\| \|A^{-1}\| = 2.01 \times 201 = 404$$

Métodos Numéricos I 2024

11

Definición de Residuo

Dado el sistema $Ax = b$, donde $A \in \mathbb{R}^{n \times n}$; $b \in \mathbb{R}^n$

Sea x_c valor calculado

$$e = x - x_c$$

$$r(x) = b - Ax_c$$

$$r(x) = Ax - Ax_c = A(x - x_c) = Ae$$

$$e = A^{-1}r$$

$$\text{si } r(x) = 0 \Rightarrow e = 0$$

Teorema: Para toda matriz $A \in \mathbb{R}^{n \times n}$ vale que

$$\frac{1}{\kappa(A)} \frac{\|r\|}{\|b\|} \leq \frac{\|e\|}{\|x\|} \leq \kappa(A) \frac{\|r\|}{\|b\|}$$

Métodos Numéricos I 2024

12

Error en Eliminación de Gauss

- Wilkinson estudió el efecto del redondeo en el método de Eliminación de Gauss, considerando la triangulación con pivoteo y la solución de los dos sistemas triangulares, concluyendo que es un proceso **muy estable**, considerando que la matriz A no sea mal condicionada.
- Una forma de chequear esto es controlando los elementos de U, si crecen mucho es una señal de mala condición de la misma
- También multiplicar la inversa por la matriz de coeficientes original y estimar si el resultado es suficientemente cercano a la matriz identidad.

MÉTODOS ITERATIVOS

Son recomendados para matrices *sparse* (ralas), caracterizadas por ordenes altos y muchos elementos nulos.

Las ventajas respecto a los métodos directos vistos se relacionan con:

- número de operaciones
- posiciones de memoria
- errores de redondeo

El principio de estos métodos es dividir a la matriz A, de forma tal que el sistema sea fácil de resolver.

A partir de $Ax = b$ generamos la ecuación: $x^{k+1} = Bx^k + c$ esta sucesión, si converge, lo hace al valor buscado $x^k \rightarrow x_v$

B se llama matriz de iteración,

Este método es una generalización del método de punto fijo

MÉTODOS ITERATIVOS

Método directo $\rightarrow O(n^3/3)$

n = 100	≈	3.3 · 10 ⁵	flops
n = 10.000	≈	3.3 · 10 ¹¹	flops
n = 100.000	≈	3.3 · 10 ¹⁴	flops

Tamaño límite más "grande" que podía ser tratado por los métodos directos:

Año	Tamaño
1950	20
1980	2000
2000	20000
....

Método de Jacobi

Escribimos

$$A = L + D + U$$

D: matriz diagonal, L y U: matrices triangulares

$$d_{ij} = \begin{cases} a_{ij} & i = j \\ 0 & i \neq j \end{cases} \quad l_{ij} = \begin{cases} a_{ij} & i > j \\ 0 & i < j \end{cases} \quad u_{ij} = \begin{cases} a_{ij} & i < j \\ 0 & i > j \end{cases}$$

Suponiendo que los $a_{ii} \neq 0 \forall i$, D es invertible

$$\begin{aligned} Ax &= b \\ (D + L + U)x &= b \\ Dx &= -(L + U)x + b \\ x &= -D^{-1}(L + U)x + D^{-1}b \end{aligned}$$

$$x^{k+1} = -D^{-1}(L + U)x^k + D^{-1}b$$

$$B = -D^{-1}(L + U) \quad c = D^{-1}b$$

Método de Jacobi

Este método se puede ilustrar usando las siguientes ecuaciones:

$$\begin{aligned} a_{11} \cdot x_1 + a_{12} \cdot x_2 + a_{13} \cdot x_3 &= b_1 \\ a_{21} \cdot x_1 + a_{22} \cdot x_2 + a_{23} \cdot x_3 &= b_2 \\ a_{31} \cdot x_1 + a_{32} \cdot x_2 + a_{33} \cdot x_3 &= b_3 \end{aligned}$$

Despejo cada x_i de la ecuación i -ésima, arrancamos de x^0

$$\begin{aligned} x_1^{(k+1)} &= \frac{b_1 - a_{12} \cdot x_2^{(k)} - a_{13} \cdot x_3^{(k)}}{a_{11}} \\ x_2^{(k+1)} &= \frac{b_2 - a_{21} \cdot x_1^{(k)} - a_{23} \cdot x_3^{(k)}}{a_{22}} \\ x_3^{(k+1)} &= \frac{b_3 - a_{31} \cdot x_1^{(k)} - a_{32} \cdot x_2^{(k)}}{a_{33}} \end{aligned}$$

Método de Jacobi

Forma Gral:

$$x_i^{k+1} = \frac{b_i - \sum_{\substack{j=1 \\ j \neq i}}^n a_{ij} \cdot x_j^k}{a_{ii}} \quad i = 1, \dots, n \quad k > 0$$

Criterios de Convergencia

$$\begin{aligned} \|x^{k+1} - x^k\| &< \varepsilon \\ \frac{\|x^{k+1} - x^k\|}{\|x^{k+1}\|} &< \varepsilon \\ k &> N \end{aligned}$$

Algoritmo Jacobi

Mientras $\|x^{k+1} - x^k\| \geq \varepsilon$ y $k < N$
 Para $i=1,2,\dots,n$
 $x_i = 0$
 Para $j=1,2,\dots,i-1,i+1,\dots,n$
 $x_i = x_i + a_{ij}x_j^k$
 Fin
 $x_i^{k+1} = (b_i - x_i) / a_{ii}$
 Fin
 Fin Mientras

Este método se dice de **aproximaciones simultaneas**

Ejemplo

$$Ax = b \Rightarrow \begin{cases} 6x_1 - 2x_2 + x_3 = 4 \\ -2x_1 + 7x_2 + 2x_3 = 1 \\ x_1 + 2x_2 - 5x_3 = -4.5 \end{cases}$$

$$x^0 = (0,0,0)$$

$$\begin{aligned} \text{It 1} \quad x_1^{(1)} &= \frac{4 + 2 \cdot 0 - 1 \cdot 0}{6} = 2/3 \\ x_2^{(1)} &= \frac{1 + 2 \cdot 0 - 2 \cdot 0}{7} = 1/7 \\ x_3^{(1)} &= \frac{-4.5 - 0 - 2 \cdot 0}{-5} = 0.9 \\ \text{It 2} \quad x_1^{(2)} &= \frac{4 + 2 \cdot (1/7) - 1 \cdot (0.9)}{6} = 0.564 \\ x_2^{(2)} &= \frac{1 + 2 \cdot (2/3) - 2 \cdot 0.9}{7} = 0.076 \\ x_3^{(2)} &= \frac{-4.5 - 2/3 - 2 \cdot (1/7)}{-5} = 1.09 \\ \text{It 3} \quad x_1^{(3)} &= \frac{4 + 2 \cdot 0.076 - 1 \cdot (1.09)}{6} = 0.510 \\ x_2^{(3)} &= \frac{1 + 2 \cdot (0.564) - 2 \cdot 1.09}{7} = -0.007 \\ x_3^{(3)} &= \frac{-4.5 - 0.564 - 2 \cdot (0.076)}{-5} = 1.043 \end{aligned} \quad \left| \begin{array}{l} x^1 - x^0 \\ x^2 - x^1 \\ x^3 - x^2 \end{array} \right|_e = \max(0.666, 0.143, 0.9) = 0.9 \\ \phantom{\text{It 3}} \phantom{x_1^{(3)}} \phantom{x_2^{(3)}} \phantom{x_3^{(3)}} = \max(0.10, 0.067, 0.19) = 0.19 \\ \phantom{\text{It 3}} \phantom{x_1^{(3)}} \phantom{x_2^{(3)}} \phantom{x_3^{(3)}} = \max(0.054, 0.083, 0.047) = 0.083$$

$$\Rightarrow x^m = (0.5, 0.1)$$

Ejemplo

$$A = \begin{bmatrix} 6 & -2 & 1 \\ -2 & 7 & 2 \\ 1 & 2 & -5 \end{bmatrix}$$

$$A = L + D + U$$

$$x^{k+1} = -D^{-1}(L+U)x^k + D^{-1}b$$

$$B = -D^{-1}(L+U) \quad \Rightarrow \quad B = \begin{bmatrix} 0 & -0.333 & 0.167 \\ -0.286 & 0 & 0.286 \\ -0.200 & -0.400 & 0 \end{bmatrix}$$

Método de Gauss Seidel

Escribimos

$$A = L + D + U$$

D : matriz diagonal, L y U : matrices triangulares

$$d_{ij} = \begin{cases} a_{ij} & i = j \\ 0 & i > j \end{cases} \quad l_{ij} = \begin{cases} a_{ij} & i > j \\ 0 & i \leq j \end{cases} \quad u_{ij} = \begin{cases} a_{ij} & i < j \\ 0 & i \geq j \end{cases}$$

Suponiendo que los $a_{ii} \neq 0 \forall i$, D es invertible

$$\begin{aligned} Ax &= b \\ (D + L + U)x &= b \\ (D + L)x &= -Ux + b \\ Dx^{k+1} &= -Lx^k - Ux^k + b \end{aligned}$$

$$x^{k+1} = -D^{-1}(Lx^k + Ux^k) + D^{-1}b$$

$$B = -(D+L)^{-1}U \quad c = (D+L)^{-1}b$$

Método de Gauss-Seidel

Este método es muy parecido al de Jacobi, la diferencia es que en Jacobi se usan todas las componentes de la iteración k -ésima, x^k , para determinar las de la iteración $(k+1)$, x^{k+1} , en cambio en Gauss-Seidel se van utilizando los valores de las incógnitas recién calculados en la misma iteración

$$a_{11} \cdot x_1 + a_{12} \cdot x_2 + a_{13} \cdot x_3 = b_1$$

$$a_{21} \cdot x_1 + a_{22} \cdot x_2 + a_{23} \cdot x_3 = b_2$$

$$a_{31} \cdot x_1 + a_{32} \cdot x_2 + a_{33} \cdot x_3 = b_3$$

Despeje cada x_i de la ecuación i -ésima, arrancamos de x^0

$$x_1^{(k+1)} = \frac{b_1 - a_{12} \cdot x_2^{(k)} - a_{13} \cdot x_3^{(k)}}{a_{11}}$$

$$x_2^{(k+1)} = \frac{b_2 - a_{21} \cdot x_1^{(k+1)} - a_{23} \cdot x_3^{(k)}}{a_{22}}$$

$$x_3^{(k+1)} = \frac{b_3 - a_{31} \cdot x_1^{(k+1)} - a_{32} \cdot x_2^{(k+1)}}{a_{33}}$$

Algoritmo Gauss-Seidel

$$\text{Forma Gral: } x_i^{k+1} = \frac{b_i - \sum_{j=1}^{i-1} a_{ij}x_j^{k+1} - \sum_{j=i+1}^n a_{ij}x_j^k}{a_{ii}}$$

Mientras $\|x^{k+1} - x^k\| \geq \varepsilon$ y $k < N$

Para $i=1,2,\dots,n$

sum=0

Para $j=1,2,\dots,i-1$,

$$\text{sum} = \text{sum} + a_{ij}x_j^{k+1}$$

Fin

Para $j=i+1,\dots,n$

$$\text{sum} = \text{sum} + a_{ij}x_j^k$$

Fin

$$\text{Fin } x_i^{k+1} = (b_i - \text{sum}) / a_{ii}$$

Fin Mientras

Ejemplo

$$Ax = b \Rightarrow \begin{cases} 6x_1 - 2x_2 + x_3 = 4 \\ -2x_1 + 7x_2 + 2x_3 = 1 \\ x_1 + 2x_2 - 5x_3 = -4.5 \end{cases}$$

$$x^0 = (0, 0, 0)$$

aproximaciones sucesivas

$$\begin{aligned} \text{It 1} \quad x_1^{(1)} &= \frac{4 + 2 \cdot 0 - 1 \cdot 0}{6} = 2/3 \\ x_2^{(1)} &= \frac{1 + 2 \cdot 2/3 - 2 \cdot 0}{7} = 0.333 \\ x_3^{(1)} &= \frac{-4.5 - 2/3 - 2 \cdot 0.333}{-5} = 1.166 \end{aligned}$$

$$\begin{aligned} \text{It 2} \quad x_1^{(2)} &= \frac{4 + 2 \cdot 0.333 - 1 \cdot 1.166}{6} = 0.583 \\ x_2^{(2)} &= \frac{1 + 2 \cdot 0.583 - 2 \cdot 1.166}{7} = -0.0236 \\ x_3^{(2)} &= \frac{-4.5 - 0.583 - 2 \cdot (-0.0236)}{-5} = 1.007 \end{aligned}$$

$$\begin{aligned} \text{It 3} \quad x_1^{(3)} &= \frac{4 + 2 \cdot (-0.0236) - 1 \cdot 1.007}{6} = 0.491 \\ x_2^{(3)} &= \frac{1 + 2 \cdot (0.491) - 2 \cdot 1.007}{7} = -0.004 \\ x_3^{(3)} &= \frac{-4.5 - 0.491 - 2 \cdot (-0.004)}{-5} = 0.9966 \Rightarrow x^m = (0.5, 0, 1) \end{aligned}$$

Métodos Numéricos I 2024

25

Método Sobrerelajación (SOR)

Este método usa un factor de ponderación para mejorar el valor calculado

$$x^{k+1} = \omega x^{k+1} + (1 - \omega) x^k \quad 0 \leq \omega \leq 2$$

Forma Gral:

$$x_i^{k+1} = (1 - \omega)x_i^k + \frac{\omega}{a_{ii}} \left[b_i - \sum_{j=1}^{i-1} a_{ij}x_j^{k+1} - \sum_{j=i+1}^n a_{ij}x_j^k \right] \quad i = 1, \dots, n$$

$0 < \omega < 1$ hace convergente el método (subrelajación)

$\omega = 1$ Gauss Seidel

$1 < \omega < 2$ acelera convergencia del método (sobre relajación)

Métodos Numéricos I 2024

26

Convergencia

Método de Jacobi: Podemos afirmar su convergencia si A es diagonalmente dominante:

$$|a_{ii}| \geq \sum_{j=1, j \neq i}^n |a_{ij}|$$

Método de Gauss Seidel: Podemos afirmar su convergencia si A es diagonalmente dominante y también si es simétrica y definida positiva

Métodos Numéricos I 2024

27

Convergencia

Teorema de Convergencia

Suponiendo tener la ecuación: $x^{k+1} = B x^k + c$, si en alguna norma matricial $\|B\| < 1$ y si x^0, x^1, \dots es la sucesión generada por esta ecuación, esta sucesión converge a la única solución x de la ecuación vectorial $x = B x + c$ independientemente del x^0 escogido

$$x^{k+1} = B x^k + c$$

$$x = B x + c$$

$$x^{k+1} - x = B(x^k - x)$$

$$e^{k+1} = B e^k$$

$$\|e^{k+1}\| = \|B\| \|e^k\| \quad \text{si } \|B\| < 1 \Rightarrow x^{k+1} \rightarrow x$$

Métodos Numéricos I 2024

28

Comparacion Métodos Directos e Iterativos

• Tiempo de ejecución	$O(n^3)$	$n^2 \times \text{iter}$
• Almacenamiento	$n \times n$	n
• Errores de redondeo	grandes	despreciable
• Tiempo de ejecución	Finito	?
• T. i. adicionales	''barato''	''caro''
• Aplicaciones	Generales	Específicas

Métodos Numéricos I 2024

29